

Trabajo Práctico Integrador

Módulo R

Alumna: María Belén Paisan

Maestría en Econometría
Universidad Torcuato Di Tella
Segundo Trimestre 2026

Informe

Este informe se encuentra dividido en tres partes, siguiendo las consignas del trabajo práctico integrador: la elección del dataset y de la técnica, el análisis exploratorio de datos (EDA) y la aplicación de la técnica e interpretación. Cada parte estará acompañada por los gráficos pertinentes, los cuales estarán numerados dentro de cada parte.

Parte 1 – Elección del dataset y de la técnica

El dataset elegido para este trabajo es la Encuesta Permanente de Hogares (EPH) publicada por el INDEC. Esta encuesta es realizada de manera trimestral por el organismo con el objetivo de “*relevar las características sociodemográficas y socioeconómicas de la población*”¹. Según el sitio web del INDEC, el relevamiento se realiza de manera telefónica y presencial a hogares de aglomerados urbanos.

El INDEC publica la base de microdatos de cada trimestre en su página web, pero para este trabajo se utilizó directamente la librería de R llamada “eph” que permite cargar directamente la base de microdatos en el programa. Se utilizaron los datos del último relevamiento disponible de la encuesta, correspondiente al primer trimestre de 2026.

La microdatos de la EPH se encuentran divididos en dos: la base perteneciente a los individuos y la perteneciente a los hogares. La primera contiene variables referentes a las personas encuestadas (su edad, género, ingreso, nivel educativo, ocupación, etc.) mientras que la segunda contiene variables referidas a las características de la vivienda (ambientes, materiales, presencia de servicios públicos, organización del hogar, etc.). Gracias al diseño de las bases de datos, se puede unir las características de la vivienda con las personas que la habitan: el informe de diseño del INDEC² explica que tanto la base de hogares como la de individuos tienen la variable CODUSU y NRO_HOGAR y que “*todos los miembros del hogar tienen el mismo CODUSU y NRO_HOGAR*”.

Por lo tanto, al unir ambas bases de datos, se podría obtener una mayor cantidad de información relacionada a cada individuo, que no solo tenga que ver con sus características personales sino también con las de su hogar. El objetivo de este trabajo es ver si esas características adicionales pueden aumentar el poder predictivo. Para ver esto, se eligió un tema en particular: el estado de ocupación (ocupado o desocupado) de las personas sin educación universitaria.

La técnica elegida para realizar este análisis es la regresión logística vista en el curso: se dividió el dataset en conjuntos de entrenamiento y testeo, se estimaron modelos logit con y sin las variables relacionadas a la vivienda y se analizó la capacidad de predicción de los modelos con matrices de confusión, curvas ROC y otras métricas analizadas en el curso. Se adicionó también una especificación adicional, utilizando la técnica de selección de variables “stepwise” para ver si una selección automática de variables podría mejorar los resultados.

¹ [\(Instituto Nacional de Estadísticas y Censos \[INDEC\], s.f.\)](#)

² [\(Instituto Nacional de Estadísticas y Censos \[INDEC\], 1T- 2026\)](#)

Cabe aclarar que el enfoque de este trabajo es la capacidad de predicción de estas variables mediante las técnicas vistas en el curso y no busca demostrar una relación de causalidad estricta. Obviamente, hay muchas variables relevantes (como la habilidad del individuo, la experiencia en el mercado de interés, el sector en el que se desempeña, factores macroeconómicos) que no están presentes en la EPH pero que afectan la probabilidad de estar desocupado. Dado que no se incluyen estas variables en el modelo, estas quedarían dentro del error, haciendo que las estimaciones de los parámetros asociados a cada variable sean inconsistentes y sesgadas (salvo que se utilizara otro método, como variables instrumentales por ejemplo). Además, tampoco se hace referencia a un modelo teórico completo que provea una estructura de causalidad. Por lo tanto, todas las conclusiones de este informe son desde el punto de vista de la aplicación de las técnicas y la capacidad de predicción de distintas variables y no desde el punto de vista de la causalidad.

Parte 2 – Análisis exploratorio de datos (EDA)

Los datasets originales contienen 43.739 individuos con 234 variables y 15.447 hogares con 98 variables. Antes de realizar el EDA, se procede a seleccionar las variables y la población relevantes para el análisis.

En cuanto a los individuos, se puede ver en el informe de diseño del INDEC (que detalla el significado de cada variable) que a partir de cierto punto todas las variables refieren a preguntas acerca del trabajo del individuo (sector, horas trabajadas, ingresos, características del empleo, etc.) o a preguntas acerca de su desocupación (razón, si tenía trabajo previo, etc.). Dado que todas estas preguntas sólo son contestadas por los ocupados en el primer caso y por los desocupados en el segundo, no tendría sentido incluirlas en un intento de predicción del estado laboral: serían predictores perfectos de ocupados y desocupados respectivamente. Por lo tanto, se eliminan todas esas variables del dataset, excepto por el ingreso no laboral del individuo.

En cuanto a los hogares, se seleccionaron para este análisis 11 variables referidas al estado de la vivienda: el tipo de vivienda, ambientes, el material de los pisos, el revestimiento interior del techo, la conexión de agua, el tipo de baño, la ubicación en una villa de emergencia, la propiedad de la vivienda, la conexión de gas, la cantidad de habitantes y la cantidad de habitantes menores de 10 años. Estas fueron seleccionadas porque resumen varias dimensiones del estado del hogar, pero podrían haber sido otras las variables elegidas.

En cuanto a la población, como ya fue mencionado, el análisis se va a enfocar en las personas sin educación universitaria. Por lo tanto, se va a filtrar la base de individuos para que solo queden los jefes de hogares (para incluir solo 1 observación por familia y que todas sean independientes), entre 18 y 65 años (edad laboral), que estén ocupados o desocupados (para eliminar a los inactivos) y cuyo nivel educativo sea primario o secundario, completo o incompleto.


Luego de todas estas modificaciones, el tamaño de los datasets se redujo a 5.492 individuos con 29 variables y 15.447 hogares con 20 variables. Sin embargo, todavía queda unir ambos datasets en uno. Para eso, no sólo se usarán las variables de “CODUSU”

y “NRO_HOGAR” que identifican a las personas y hogares sino también el resto de lo que el informe de diseño del INDEC llama variables de identificación: año, trimestre, región, aglomerado, etc. que son variables que son iguales en ambos datasets. Al finalizar esta unión, el dataset queda con 5492 individuos con 41 variables.


A continuación, luego de renombrar algunas variables, se pasó al análisis exploratorio de cada variable. En cuanto a códigos de no respuesta, el informe de diseño del INDEC explica que estos son 9, 99, 999 o 9999. Si estos estuvieran presentes, será notorio en los gráficos de las siguientes páginas pero existe un código específico para la no respuesta en ingresos, -9, que vale la pena analizar para la variable de ingresos no laborales.

La cantidad individuos que no respondieron acerca de sus ingresos no laborales son 140. Dado que representan solo 2,5% de una muestra de más de 5000 individuos, se optó por eliminar estas observaciones en vez de introducir ruido adicional mediante algún método de imputación.

En cuanto a la distribución del ingreso no laboral, como se puede observar en el gráfico, hay una gran concentración en el cero pero también hay observaciones con valores de hasta 20 millones. Se analizó la posibilidad de utilizar el logaritmo de esta variable, pero dada la gran cantidad de personas que no tienen ingreso no laboral, la imposibilidad de aplicar el logaritmo a cero eliminaría una gran cantidad de observaciones. Por lo tanto, se optó por expresar la variable en millones para readecuar la escala, teniendo en cuenta que el resto de las variables son, en su mayoría, categóricas.



En cuanto al resto de las variables, también se realizaron recodificaciones de sus valores originales. En cuanto a la variable dependiente de este ejercicio, el estado de ocupación del individuo, se transformó para que 1 represente desocupado y 0 ocupado. Algo similar se realizó para la variable género, en donde las mujeres se representan con un 0



en vez del 2 de la base original. En el gráfico 2.2 se puede observar que la proporción de hombres es mayor a la de mujeres pero ambas categorías tienen observaciones de desocupados y ocupados. Esto último es importante para que la variable no sea un predictor perfecto del estado de ocupación. También cabe aclarar que todos los gráficos

del EDA utilizan la variable PONDERA de la EPH como factor de expansión para cada observación.




Gráfico 2.3




Gráfico 2.4

En cuanto al estado civil, en el gráfico 2.3 se pueden observar las categorías originales de la variable. En este contexto, tiene sentido unir las dos categorías que representan uniones (unido y casado) y juntar el resto de las opciones en otra categoría. El resultado se puede ver en el gráfico 2.4, en donde hay un mayor porcentaje de separados, divorciados, viudos o solteros.

En cuanto al nivel educativo, en el gráfico 2.5 se puede observar la distribución de los distintos niveles educativos máximos alcanzados. Dado que el nivel educativo puede ser una característica importante para el estado de ocupación, se optó por crear una dummy para cada nivel y dejar “Sin instrucción” como la categoría base.




Gráfico 2.5

En cuanto a la variable referida a la región, como muestra el gráfico 2.6, el Gran Buenos Aires representa la mayor cantidad de observaciones. Como las regiones del país son muy distintas entre sí, no sería correcto juntar todas bajo una dummy como “No Buenos Aires”, por lo que se dejó la categoría Gran Bs. As. como base y se generaron dummies para el resto de las regiones.




Gráfico 2.6

La variable MAS_500 (en la siguiente página) también se recodificó para cambiar sus códigos de letras a 0 y 1 para indicar un aglomerado de menos o más de 500.000 habitantes.

En cuanto a las variables de vivienda, la primera es el tipo de vivienda. Dado que la pieza en inquilinato, hotel o pensión o vivienda en local no tienen muchas observaciones, se optó por agrupar todas estas últimas en una sola categoría con su propia dummy, crear una dummy específica para departamento, y dejar las viviendas en casas (las mayoritarias) como base.

Algo similar sucede con el material de los pisos interiores: los pisos más comunes (mosaico, baldosa, madera, cerámica o alfombra) se diferencian bastante de las otras categorías. Pero, en este caso, se eligió generar una dummy que vale 1 si el piso es de esta categoría mayoritaria y 0 si pertenece a alguna de las otras.

En cuanto al gráfico 2.10, solamente se necesitó recodificar la variable en 0 y 1 ya que solo había dos opciones para el cielorraso o revestimiento interior del techo: tenerlo o no.




Gráfico 2.7



Gráfico 2.8




Gráfico 2.9




Gráfico 2.10

En cuanto a la conexión de agua que posee la vivienda, tener cañería dentro de la vivienda es la más común y el resto de las categorías tienen muy baja ocurrencia, por lo que se mantuvo esa categoría como base y se generó una dummy que es igual a 1 para el resto de las opciones.




Gráfico 2.11

El resto de las recodificaciones de las variables se pueden observar en los siguientes gráficos.




Gráfico 2.12




Gráfico 2.13



Gráfico 2.14

En cuanto al tipo de baños, el procedimiento fue similar al de la conexión de agua, dejando la categoría mayoritaria (inodoro con arrastre de agua) como categoría base.

En cuanto a la ubicación de la vivienda en una villa de emergencia, al igual que el techo, solamente se recodificó en 0 y 1. En el gráfico 2.13 pareciera que no hay desocupados que vivan en villas de emergencia, pero solo es un problema de escala del gráfico y de la utilización del factor de expansión.

En el gráfico 2.14 se pueden ver las distintas opciones disponibles para la propiedad de la vivienda: propietario de vivienda y terreno, propietario de vivienda, inquilino, ocupante por pago de impuestos o expensas, ocupante en rel. de dependencia, ocupante gratuito (con permiso), ocupante de hecho (sin permiso), en sucesión u otros. Para esta variable se optó por generar dummies para ciertas categorías: una que agrupa las dos maneras de propietario (de vivienda y terreno o solo vivienda), otra que agrupa a los inquilinos y dejar el resto de las categorías minoritarias como base (iguales a 0 en ambas anteriores).

La última de las recodificaciones/reagrupaciones fue del tipo de conexión a gas, en donde se generó una dummy para indicar la conexión de gas por medio de tubo o garrafa, kerosene, leña, carbón u otros, dejando la categoría mayoritaria de gas de red como base.




Gráfico 2.15

En los gráficos anteriores la aparición del cero en el eje x se debe a que la persona no le correspondía la pregunta de la encuesta. Por ejemplo, no corresponde el tipo de baño si no tiene baño. Se incluyeron esas personas en las recodificaciones junto con otras categorías minoritarias.

Hubo 4 variables que no requirieron recodificación o generación de dummies ya que se trataba de variables continuas. A continuación se muestran gráficos de las variables, para ver su distribución en los distintos estados de ocupación y comprobar que no haya ningún código de no respuesta de los mencionados anteriormente (y que sea incoherente con los valores de la variable, ya que por ejemplo, una vivienda con 9 ambientes no necesariamente indica no respuesta).

Distribución de Edad




Gráfico 2.16

Distribución de cantidad de miembros del hogar




Gráfico 2.17

Distribución de cantidad de miembros del hogar menores de 10 años




Gráfico 2.18

Distribución de cantidad de ambientes de la vivienda




Gráfico 2.19

En cuanto a la variable edad, se puede observar en el primer gráfico que la distribución entre los ocupados es bastante uniforme, mientras que para los desocupados se tiende a concentrar hacia el centro del rango de edad: hay menos desocupados en el rango de los 20 y casi 65 años. Esto tal vez se debe a que las personas de esa edad tienden a clasificarse como inactivos más que desocupados.

En cuanto a la cantidad de miembros en el hogar, tanto desocupados como ocupados tienden a concentrarse en valores bajos de cantidad de miembros pero puede verse que los ocupados pueden llegar a tener una mayor cantidad. Lo mismo sucede con la cantidad de miembros menores a 10 años de edad.

Por último, el gráfico 2.19 muestra la distribución de la cantidad de ambientes de la vivienda. Al igual que en las variables anteriores, estas tienden a concentrarse en valores bajos pero son los ocupados los que pueden llegar a tener viviendas más grandes.

Al interpretar el significado de estas variables hay que tener en cuenta la advertencia realizada acerca de la causalidad: es imposible saber sin un modelo teórico detrás o mayor información si, por ejemplo, la mayor cantidad de ambientes causa que los individuos deban trabajar más o si debido a que trabajan pueden comprar viviendas con mayor cantidad de ambientes.

Como último paso del EDA, se comprobó que no hubiera NAs en alguna de las variables a utilizar en el análisis: el control fue exitoso.

Parte 3 – Aplicación de la técnica e interpretación

Como primer paso, se analiza el balance de la muestra en cuanto a la variable dependiente, el estado de ocupación. En el gráfico 3.1 se puede observar que claramente la muestra está desbalanceada: exactamente, hay un 95,44% de ocupados y un 4,56% de desocupados. Esto deberá tenerse en cuenta en dos instancias. En primer lugar, al dividir la muestra en datos de entrenamiento y de testeo, se deberá comprobar que el desbalance siga siendo similar. Puede verse en el gráfico 3.2 que, una vez realizada la separación de manera aleatoria (70% de datos a entrenamiento y 30% a testeo), se siguen respetando las proporciones. Exactamente, hay un 95,78% de ocupados y un 4,22% de desocupados en la submuestra de entrenamiento, por lo que la diferencia es solamente en los decimales.




Gráfico 3.1




Gráfico 3.2

En segunda instancia, este desbalance deberá ser tenido en cuenta para el umbral de decisión, cuando se pase de las probabilidades predichas por el modelo a categorías de ocupado o desocupado. Se discutirá más adelante acerca de esto.

La primera estimación a considerar es un modelo logit que usa como regresores solamente las variables de la base de individuos: género, edad, las dummies del nivel educativo, el estado civil, la dummy de cantidad de habitantes en el aglomerado, las dummies de región y el ingreso no laboral. Siendo ESTADO la variable que indica si la persona está ocupada o desocupada, el modelo logit establece la siguiente definición de probabilidad:

$$P(ESTADO = 1|X) = \frac{1}{1 + \exp(-X\beta)}$$

siendo $X\beta$ las variables mencionadas junto con sus coeficientes

El modelo se estima con la herramienta glm de R. Vale aclarar que en esta parte del trabajo no se utilizaron los factores de expansión PONDERA, ya que, según la documentación del comando, los pesos que permite la fórmula no se refieren necesariamente a factores de expansión (son más bien referidos a los éxitos de la distribución binomial de fondo). Tal vez existan otros comandos para tener estos factores de expansión en cuenta pero exceden lo visto en el curso. Sin embargo, uno esperaría que, si los factores de expansión solo controlan por el “tamaño”, las relaciones encontradas no deberían ser muy distintas.

Tabla 3.1	Coefficiente	S.E	P_Value	Cambio en odds
(Intercept)	-1.36	1.154	0.239	0.257
genero	-0.209	0.178	0.241	0.812
edad	-0.02	0.008	0.01	0.98
prim_inc	-0.429	1.099	0.696	0.651
prim_com	-0.784	1.065	0.462	0.456
sec_inc	-0.974	1.065	0.36	0.378
sec_com	-1.236	1.061	0.244	0.291
e_civil	-0.125	0.176	0.479	0.883
MAS_500	0.466	0.213	0.029	1.593
nor_o	-0.499	0.324	0.123	0.607
nor_e	0.244	0.387	0.528	1.277
cuyo	-0.909	0.432	0.036	0.403
pampa	0.329	0.248	0.185	1.389
patag	-0.238	0.394	0.546	0.788
ingreso_no_laboral	0.951	0.209	0	2.587
AIC	1280.689			

En la tabla anterior se muestran los resultados del primer modelo logit. Se encuentran resaltadas las variables que resultaron estadísticamente significativas (a un nivel del 5%): la edad, la cantidad de habitantes en el aglomerado, vivir en la región cuyana y el ingreso no laboral son relevantes para predecir el estado de ocupación del individuo. En términos de interpretación, al ser un modelo logit, los coeficientes por sí mismos no representan el efecto marginal, pero si se puede extraer de ellos el signo del efecto: una mayor edad o residir en la región de cuyo tienen un efecto negativo sobre estar desocupado, mientras que residir en un aglomerado de más de 500.000 habitantes o un mayor ingreso laboral tienen un efecto positivo.

Como fue visto en el curso, si se aplica exponencial a los coeficientes de los modelos logit se puede obtener el cambio en el odds ratio al aumentar una unidad la variable o activarse la dummy. Por ejemplo: según la última columna de la tabla, un año más de edad multiplica los odds de que se prediga estar desocupado (versus no estarlo) por 0.98, es decir que disminuye los odds en 2%. De la misma manera, vivir en un aglomerado de mayor cantidad de habitantes aumenta los odds en 59,3%, vivir en la región de cuyo los disminuye en 59,7% y una unidad de ingreso no laboral los aumenta en 158,7%. En cuanto a este último dato, hay que tener en cuenta que la variable estaba medida en millones, pero se podría pensar que tal vez las personas que buscan ingresos no laborales son las que lo necesitan y por eso es que un mayor ingreso laboral podría predecir la desocupación.

Una vez estimado el modelo, se lo utilizó para realizar la predicción del estado de ocupación de los individuos en el conjunto de testeo. Como fue mencionado antes, el

modelo genera predicciones de probabilidad que debemos transformar en categorías de ocupado y desocupado, teniendo en cuenta el balance original de la muestra. Si el umbral elegido para clasificar como desocupado es 0.5 (es decir, si se requiere una probabilidad estimada de estar desocupado mayor a 0.5 para clasificar como tal), ocurre lo expresado en el siguiente gráfico 3.3 (izquierda): solamente se predice 1 desocupado en todos los datos de testeo y además, es un falso positivo, porque el estado real de esa persona es ocupado.

Matriz de Estado predicho vs Estado Real con umbral de 0.5




Gráfico 3.3

Matriz de Estado predicho vs Estado Real con umbral modificado




Gráfico 3.4

Al ser baja la proporción de desocupados en la muestra, las probabilidades de estarlo que predice el modelo estimado son también muy bajas. Debido a esto, casi ninguna llega al umbral de 0.5 necesario para clasificar como desocupado (solo hay un caso, que parecería ser muy atípico, porque es un falso positivo). De esta manera, se maximiza la “accuracy” o exactitud porque predice 1605 ocupados, de los cuales 1519 son correctos, pero se equivoca en la totalidad de los desocupados (86) clasificándolos como ocupados.

Esto puede modificarse, como se ve en el gráfico 3.4 (derecha), ajustando el umbral a partir del cual un individuo es clasificado como desocupado. Para este ejercicio se eligió la proporción que había en la muestra original como umbral. Se puede ver en el gráfico que la predicción de desocupados es mucho mejor: de los 86 desocupados totales en los datos de testeo, la mayoría (51) son clasificados como desocupados. Sin embargo, esto se logra sacrificando otras métricas. Utilizando las métricas vistas en clase, la precisión es muy baja, ya que ahora se están clasificando demasiados individuos como desocupados ($640 + 51 = 691$) cuando la cantidad real era mucho menor. La sensibilidad del modelo también sufre, ya que disminuyeron en gran medida (de 1519 a 880) los predichos correctamente como ocupados (aunque la mayoría de los ocupados reales siguen siendo clasificados correctamente). La decisión entre ambos umbrales va a depender de qué error es más aceptable por el usuario: no detectar ningún desocupado y clasificar a todos (menos uno) como ocupados, o detectar a la mayoría de los desocupados a costa de clasificar erróneamente a individuos que en realidad sí están ocupados. Dado que el objetivo del ejercicio es predecir la desocupación, se continuará con el segundo umbral.

En el gráfico 3.5 (siguiente página), se expone la curva ROC, junto con el valor del AUC (área debajo de la curva) para esta especificación. Como fue visto en clase, el óptimo estaría en la esquina superior izquierda con 1 de sensibilidad (detectar correctamente los desocupados) y 1 de especificidad (detectar correctamente los ocupados). Este modelo está lejos de eso, pero es mejor que el azar (que sería un AUC de 0.5).





Gráfico 3.5

A continuación, se procederá a analizar si agregar las variables relacionadas con la vivienda de los individuos pueden mejorar la capacidad de predicción discutida anteriormente. La estimación del modelo con las variables agregadas produjo los siguientes resultados:

Tabla 3.2	Coefficiente	S.E	P_Value	Cambio en odds
(Intercept)	-0.929	1.238	0.453	0.395
genero	-0.184	0.183	0.315	0.832
edad	-0.017	0.009	0.05	0.983
prim_inc	-0.44	1.11	0.692	0.644
prim_com	-0.716	1.077	0.506	0.488
sec_inc	-0.907	1.079	0.401	0.404
sec_com	-1.09	1.078	0.312	0.336
e civil	-0.142	0.197	0.47	0.867
MAS_500	0.421	0.219	0.054	1.524
nor_o	-0.563	0.331	0.088	0.569
nor_e	0.154	0.402	0.701	1.167
cuyo	-0.939	0.439	0.032	0.391
pampa	0.339	0.251	0.177	1.404
patag	-0.201	0.405	0.62	0.818
ingreso_no_laboral	0.953	0.214	0	2.593
ambientes	0.013	0.084	0.88	1.013
pisos	-0.632	0.232	0.006	0.532
techo	0.057	0.239	0.812	1.059
agua	-0.337	0.583	0.563	0.714
baño	0.038	0.317	0.903	1.039
v_emer	-0.616	0.743	0.407	0.54
propiedad	-0.34	0.22	0.123	0.712
gas	0.002	0.202	0.993	1.002
cant_miembros	0.032	0.069	0.648	1.032
cant_menores	-0.015	0.137	0.913	0.985
depto	0.137	0.22	0.531	1.147
pieza_local	-0.124	1.054	0.907	0.884
inq	-0.414	0.276	0.134	0.661
AIC	1293.848			

Comparando con el primer modelo estimado, algunas variables como edad o la cantidad de personas en el aglomerado ya no resultan significativas (aunque sí lo serían si se tomara un nivel de significatividad de 10%). La dummy de región de cuyo y la variable de ingreso laboral siguen siendo significativas, con coeficientes y cambios en odds similares. De las nuevas variables agregadas, la única significativa a un nivel del 5% es la referida al material de los pisos: tener pisos de mosaico, baldosa, madera, cerámica o alfombra disminuye los odds en 46,8%. El AIC de este modelo es más alto que el anterior.

Parecería que agregar las variables de vivienda no otorgó mucho poder predictivo adicional. Sin embargo, podemos analizar también la matriz de confusión y la curva ROC:



Tanto la matriz como la curva ROC fueron realizadas con el mismo umbral que para el primer modelo estimado. Se podría pensar que esta es una especificación más “equilibrada” que el modelo anterior: sigue prediciendo correctamente la mayoría de los ocupados y los desocupados reales, pero la tendencia a “sobre clasificar” como desocupado es menor. Antes había clasificado a 691 como desocupados y ahora solo a 642 (593+49). Esto hace que la “accuracy” y la especificidad mejoren ya que detecta correctamente a más ocupados (que son la mayoría en la muestra). Si bien la sensibilidad sufre (porque hay menos casos de predicción correcta de desocupados reales), pareciera que el “trade-off” resulta positivo porque el AUC de esta curva ROC es ligeramente mayor (0.660 versus 0.654 anteriormente).



Por último se intentará una última especificación de la estimación, utilizando la técnica de selección automática “stepwise”. El algoritmo (en su versión “both”, hacia adelante y hacia atrás) hará una selección automática entre todas las variables según el criterio de AIC que resulte de cada modelo probado.

La especificación elegida por el algoritmo fue una regresión sobre ingreso no laboral, las dummies de región pampeana, cuyo y noroeste, la dummy de pisos, la de cantidad de habitantes en el aglomerado, la de secundario completo y la variable de edad. Resulta curioso que muchas de las variables elegidas no resultaron significativas en los modelos anteriormente analizados. Los resultados de la estimación fueron:

Tabla 3.3	Coefficiente	S.E	P_Value	Cambio en odds
(Intercept)	-2.096	0.389	0	0.123
ingreso_no_laboral	0.955	0.201	0	2.599
pampa	0.36	0.182	0.048	1.433
pisos	-0.668	0.2	0.001	0.513
MAS_500	0.464	0.168	0.006	1.59
cuyo	-0.886	0.411	0.031	0.412
nor_o	-0.527	0.276	0.056	0.59
edad	-0.016	0.008	0.04	0.984
sec_com	-0.291	0.172	0.09	0.748
AIC	1265.715			

Puede observarse en la tabla anterior que la mayoría de las variables resultan significativas, a diferencia de lo que pasaba en los modelos anteriores. Incluso las dos variables que no se encuentran resaltadas (las dummies de región noroeste y secundario completo) resultarían significativas a un nivel de 10% de significatividad. En esta especificación, mayor ingreso laboral, vivir en la región pampeana o en aglomerados de más de 500.000 habitantes tienen un efecto positivo y un mejor material de pisos, vivir en la región de cuyo o mayor edad tienen un efecto negativo.

Matriz de Estado predicho vs Estado Real con umbral modificado



Sin embargo, al evaluar la matriz de confusión y la curva ROC, se puede observar que la selección automática por criterio de AIC no es tan buena. El número de AUC (0.648) es el menor de todos los evaluados hasta el momento. Esto tiene que ver con lo que está pasando en la matriz de confusión: la sensibilidad es la misma que en el caso anterior, porque de los verdaderamente desocupados (68) predice correctamente 49, pero pierde en especificidad y “accuracy” porque el número de ocupados predichos correctamente es menor y la cantidad de individuos en general clasificados como desocupados aumentó ($630 + 49 = 679$). Este caso no tiene ninguna de las ventajas de las dos estimaciones anteriores: no predice correctamente tantos verdaderos desocupados como el primer modelo (el de las variables únicamente del individuo) pero tampoco tantos verdaderos

ocupados como el segundo (el de que agrega variables de la vivienda). Se encuentra en un punto medio, que resulta perjudicial (evidenciado por la baja en el AUC).

Conclusión

En cuanto a la pregunta que se buscaba resolver, de si agregar variables acerca de la vivienda de los individuos sin educación universitaria puede mejorar una predicción acerca de su estado laboral, la respuesta fue afirmativa (ligeramente). El segundo modelo analizado, que incluía todas las variables individuales y de hogares seleccionadas, reportó una matriz de confusión con mejores métricas y una curva ROC con un mejor AUC. Si bien esta última métrica está lejos de 1 (que sería una predicción perfecta), el modelo se comporta mejor que el azar (que sería un AUC de 0,5). Obviamente, y como fue mencionado al principio del trabajo, el modelo se encuentra limitado por la falta de variables que no están disponibles en la EPH (u otra selección de variables, tal vez) y otros métodos que también proveerían de un marco causal más allá de la predicción, pero queda demostrado que hay cierta capacidad predictiva que puede ser extraída de estas variables.

Las limitaciones de este ejercicio se fueron mencionando a lo largo del informe pero la más importante tiene que ver con la baja proporción de desocupados. Al tener una proporción baja, las probabilidades son bajas y se debe usar el umbral de clasificación para corregir la asignación. Esto genera que la matriz de confusión pueda ser muy sensible a pequeños cambios en el umbral y que haya que admitir errores grandes (como por ejemplo, predecir más de 600 desocupados cuando en realidad hay 68) para capturar algún porcentaje importante de la categoría objetivo. La aplicación de la selección automática vía “stepwise” también deja una advertencia: no siempre una selección de variables con un AIC mínimo será la óptima en términos de clasificación y AUC.

Como conclusión final, si bien la especificación completa (con variables del individuo y del hogar) tal vez no sirva para predecir un número preciso de la cantidad de desocupados, agregar más información logró mejorar la clasificación bajo el mismo umbral.

Referencias utilizadas:

- Apuntes de clase.
- Scripts de R de las clases del curso.
- Instituto Nacional de Estadísticas y Censos. *Operaciones Estadísticas del INDEC*. <https://www.indec.gob.ar/indec/web/Institucional-Indec-OperacionesEstadisticas> y *Diseño de registros y estructura para las bases preliminares (hogares y personas)*. https://www.indec.gob.ar/ftp/cuadros/menusuperior/eph/EPH_registro_1T2026.pdf